浮点数的乘除法运算

一₌总体思路

- 1. 从标准输入读入两个浮点数保存在两个 float 当中
- 2. 通过 union 对其对应的 unsigned long 进行位运算,得到乘除法结果
- 3. 输出结果,对比计算机原本的运算和我实现的运算的区别

二.算法证明

1. 乘法

$$x \times y = 2^{(E \times + E y)} \cdot (M_x \times M_y)$$

细节: Mx * My 时需要先将 1 补上,而且乘得的积可能会有进位,为保证规范化可能需要让阶码+1。

2. 除法

$$\times \div y = 2^{(E \times -E y)} \cdot (M_{\times} \div M_{y})$$

细节:同样 Mx / My 时需要先将 1 补上,如果不够除,还需要进行对应的移位,同时阶码要做对应的处理。

三.使用方法

源文件 float.c 在文件夹 src 当中,可直接编译运行。

输入两个合法的浮点数,能得到多行结果,分别是程序实现的乘除法得数, c 语言自身实现的乘除法得数,以及他们的 2 进制表示。

若在 linux 系统中,可直接使用 make 命令编译得到可执行程序,再通过命令 cat test.txt | ./true_form.out 来得到实例分析中的测试结果。

四.特殊处理

对于尾数的处理,我采用了直接截断的方式,即没有进位。所以可以发现很多例子当中 c 语言实现,与程序实现的得数 2 进制码尾数相差 1,采用这种方法可适当提高运算速度,省去了对尾数运算后几位的判断,但精度稍差。

五.实例

1.0001 15.789

mul:

div:

0.0633415579795837402343750000000000000000

0.0633415728807449340820312500000000000000

 $00111101100000011011100100111000 \\ 00111101100000011011100100111010$

985347.456 125.410154

mul:

div:

01001100111010111011001000101100 010011001110111011001000101100

-123.456 987.654

mul:

div:

-0.12499924004077911376953125000000000000000

-0.12499924004077911376953125000000000000000

0100011111110111000100101111100111 010001111110111000100101111101000

001111011111111111111111110011010

0011110111111111111111111110011010

-15.469 -1.00001

mul:

div:

15.468844413757324218750000000000000000000 15.4688453674316406250000000000000000000000

01000001011101111000000001100011 0100001011101111000000001100100

32154789.2 0.1254796

mul:

div:

 $0.1254796\ 32154789.2$

mul:

 div:

 $0.0000000039023602127485901291947811841965 \\ 0.000000039023606568377999792573973536491$

 $00110001100001100001010110000110\\00110001100001100001010110000111$